RINGKASAN ANALISIS DATA AIR PASSENGER SATISFACTION

Praktikum Artificial Intelligence — Audit Data, Pre-processing, EDA, dan Evaluasi Model

1. Tujuan Analisis

Analisis ini bertujuan memeriksa kualitas dataset kepuasan penumpang pesawat, menyiapkan data untuk analisis, mengeksplorasi pola kepuasan melalui grafik, dan membandingkan performa model klasifikasi untuk memprediksi kategori kepuasan penumpang.

2. Audit Data

Pemeriksaan	Train	Test
Jumlah baris	103.904	25.976
Jumlah kolom	25	25
Duplikasi baris	0	0
Total nilai kosong	310	83
Kolom dengan nilai kosong	1	1
Jumlah kelas target	2	2

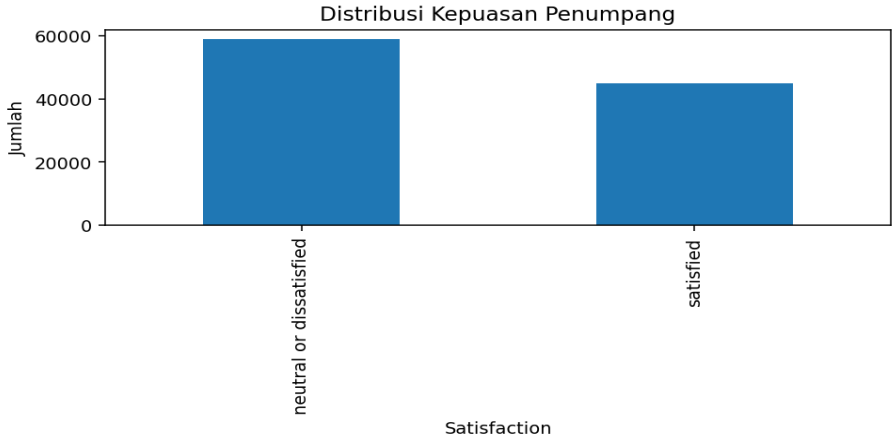
Hasil audit menunjukkan dataset train memiliki 103.904 baris dan dataset test 25.976 baris, masing-masing dengan 25 kolom. Tidak ditemukan baris duplikat. Nilai kosong ditemukan pada satu kolom di masing-masing dataset. Target memiliki dua kelas kepuasan. Kolom identifier seperti id atau Unnamed: 0 tidak digunakan sebagai fitur prediktif karena tidak merepresentasikan karakteristik layanan.

3. Pre-processing Data

Data dipisahkan menjadi fitur dan target. Kolom identifier yang tidak relevan dikeluarkan. Fitur numerik dan kategorikal diproses sesuai jenis datanya; nilai numerik yang kosong diimputasi menggunakan median, sedangkan nilai kategorikal menggunakan modus. Tahapan imputasi ditempatkan dalam pipeline agar parameter imputasi dipelajari dari data latih dan mengurangi risiko data leakage. Fitur kategorikal juga perlu dikodekan agar dapat digunakan oleh model klasifikasi.

4. Exploratory Data Analysis (EDA)

EDA dilakukan untuk melihat distribusi kelas kepuasan, membandingkan kepuasan menurut kelas penerbangan dan jenis perjalanan, melihat sebaran usia menurut kepuasan, memeriksa korelasi antarf fitur numerik, serta membandingkan rata-rata skor layanan. Grafik membantu mengidentifikasi pola awal dan fitur yang mungkin berhubungan dengan kepuasan. Pola tersebut bersifat deskriptif dan tidak dapat langsung diartikan sebagai hubungan sebab-akibat.



Gambar 1. Distribusi kategori kepuasan pada data yang dianalisis.

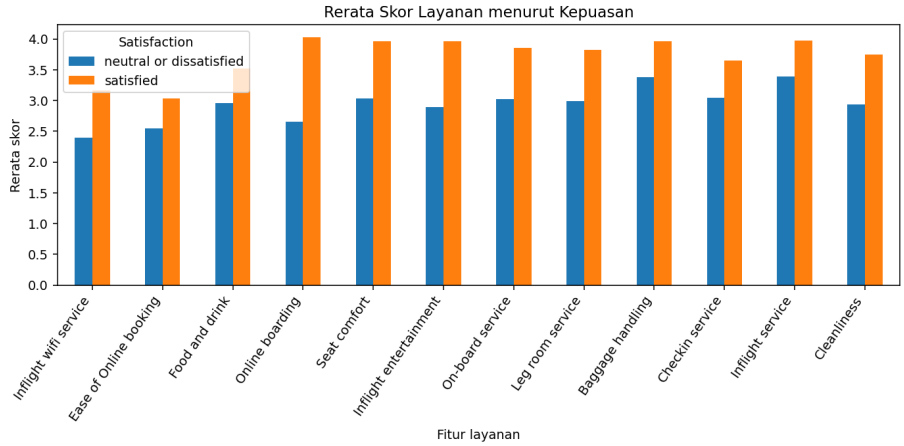
5. Hasil Perbandingan Model

Dua model yang dibandingkan adalah Logistic Regression dan Random Forest. Evaluasi dilakukan pada validation set dengan accuracy, Macro-F1, balanced accuracy, ROC-AUC, serta waktu pelatihan.

Metrik	Logistic Regression	Random Forest
Accuracy	87,65%	96,21%
Macro-F1	87,38%	96,13%
Balanced accuracy	87,24%	96,00%
ROC-AUC	92,81%	99,42%
Waktu latih	1,04 detik	3,46 detik

Random Forest memberikan hasil validation lebih tinggi pada seluruh metrik yang ditampilkan, dengan waktu pelatihan lebih lama dibandingkan Logistic Regression. Pada test set, Random Forest memperoleh accuracy sekitar 96,29% dan Macro-F1 sekitar 96,22%. Confusion matrix dan classification report digunakan untuk memeriksa prediksi benar maupun salah pada masing-masing kelas.

6. Temuan EDA dan Interpretasi Fitur



Gambar 2. Rata-rata skor layanan yang dieksplorasi pada dataset.

Permutation importance pada validation set menunjukkan bahwa Type of Travel dan Inflight wifi service memberikan penurunan Macro-F1 terbesar ketika nilai fiturnya diacak. Customer Type dan Online boarding juga termasuk fitur yang cukup berpengaruh pada model. Hasil ini menunjukkan kontribusi fitur terhadap prediksi model, bukan bukti bahwa fitur tersebut secara langsung menyebabkan kepuasan.

7. Kesimpulan dan Keterbatasan

Dataset dapat digunakan untuk analisis setelah penanganan nilai kosong dan pemilihan fitur yang sesuai. EDA memberikan gambaran distribusi kepuasan dan pola pada atribut layanan. Berdasarkan perbandingan yang dilakukan, Random Forest menjadi model dengan performa lebih baik daripada Logistic Regression pada data validasi, dan hasil evaluasi test juga menunjukkan performa tinggi. Meski demikian, performa model tidak menjamin hasil yang sama pada data lain. Korelasi dan permutation importance tidak membuktikan sebab-akibat, dan test set sebaiknya digunakan untuk evaluasi akhir, bukan tuning berulang.

Catatan: angka diringkas dari tabel hasil analisis yang tersimpan di folder output. Interpretasi bersifat deskriptif dan mengikuti evaluasi model pada dataset ini.